PDU 2025/2026

Projekt (max. = 20 p.)

1 Analiza Danych - projekt grupowy

1.1 Ważne informacje

Zadanie rozwiązujemy w grupach dwu- lub trzyosobowych.

Do **4 maja 2026 godz. 14:00** należy zgłosić skład zespołów (wystarczy by zrobiła to jedna osoba z zespołu) przy użyciu formularza dostępnego pod adresem: https://forms.cloud.microsoft/e/XHF2EgUWnV

Prace domowe należy przesłać za pośrednictwem platformy `LeON` (jedna osoba z zespołu) – **jedno archiwum `.zip`**[1] o nazwie typu `nralbumu1_nralbumu2_nralbumu3.zip` (gdzie `nralbumu+1,2,3` oznacza numery albumów poszczególnych członków zespołu). W archiwum znajdować się powinien jeden katalog, w którym umieszczone zostaną następujące pliki:

- prezentację (slajdy) przedstawiającą wyniki analizy danych (PDF lub HTML) – to *głównie* na jej podstawie zostanie wystawiona ocena;
- wszystkie skrypty `.R`, moduły / skrypty `.py`, notatniki `ipynb` pozwalające na odtworzenie zawartych w prezentacji wyników.

  Projekt może zostać wykonany przy użyciu języka `Python`, `R` lub obu.

  W prezentacji należy zacytować źródło danych, tak jak zrobiono to w tym dokumencie (zob. paragraf: Źródło danych).

Prezentacje: Zgodnie z terminami wskazanymi w harmonogramie przedmiotu na XV zajęciach (wykład, laboratorium i projekt) każda grupa przedstawi najciekawsze ich zdaniem wyniki. Prezentacja grupy powinna trwać nie dłużej niż **10 minut na prezentację projektu dla zespołów 2-osobowych, 15 dla 3-osobowych**. Wygłoszenie prezentacji jest warunkiem koniecznym uzyskania pozytywnej oceny.

($\star$) W przypadku gdy zespół składa się z osób z różnych grup laboratoryjnych prowadzący wskazuje w której grupie zajęciowej zespół wygłosi prezentację.

1.2 Cel projektu

Niniejsza praca domowa to prawdziwe wyzwanie *data science* – każda grupa sama stawia ciekawe (dla siebie i słuchaczy) pytania i generuje na nie odpowiedzi na podsatwie danych w postaci wykresów i/lub tabel.

1.3 Dane do analizy

Będziemy pracować na danych dotyczących utworów dosępnych na platformie Spotify obejmujący utwory wraz z przypisanymi im cechami (m.in. audio) z obszaru ok. 114 różnych gatunków muzycznych. Każdy gatunek muzyczny (ang. *genre*) to osobny plik `.csv` o następującej strukturze:

- **track_id**: Identyfikator Spotify dla utworu

[1] A więc nie: .rar, .7z itp.

- **artists**: Nazwy artystów, którzy wykonali utwór. Jeśli jest więcej niż jeden artysta, są oni oddzieleni średnikiem (;)
- **album_name**: Nazwa albumu, na którym znajduje się utwór
- **track_name**: Nazwa utworu
- **popularity**: Popularność utworu to wartość od 0 do 100, gdzie 100 oznacza najwyższą popularność. Jest ona obliczana algorytmicznie i opiera się głównie na łącznej liczbie odtworzeń oraz na tym, jak niedawno te odtworzenia miały miejsce. Ogólnie rzecz biorąc, utwory często odtwarzane obecnie mają wyższą popularność niż te, które były popularne w przeszłości. Zduplikowane utwory (np. ten sam utwór wydany jako singiel i na albumie) są oceniane niezależnie. Popularność artysty i albumu jest wyprowadzana matematycznie z popularności utworów
- **duration_ms**: Długość utworu w milisekundach
- **explicit**: Czy utwór zawiera wulgarne treści (true = tak; false = nie lub brak danych)
- **danceability**: Wskaźnik taneczności określa, na ile utwór nadaje się do tańca, na podstawie takich elementów jak tempo, stabilność rytmu, siła bitu i ogólna regularność. Wartość 0.0 oznacza najmniejszą taneczność, a 1.0 największą
- **energy**: Energia to miara od 0.0 do 1.0, odzwierciedlająca postrzeganą intensywność i aktywność utworu. Utwory o wysokiej energii są zwykle szybkie, głośne i dynamiczne. Na przykład death metal ma wysoką energię, podczas gdy preludium Bacha ma niską wartość na tej skali
- **key**: Tonacja utworu. Wartości całkowite odpowiadają wysokościom dźwięków zgodnie ze standardową notacją Pitch Class (np. 0 = C, 1 = Cis/Des, 2 = D itd.). Jeśli nie wykryto tonacji, wartość wynosi -1
- **loudness**: Ogólna głośność utworu w decybelach (dB)
- **mode**: Tryb (modalność) utworu, czyli określenie, czy jest w tonacji durowej czy molowej. Dur oznaczony jest jako 1, a moll jako 0
- **speechiness**: Wskaźnik obecności mowy w utworze. Im bardziej nagranie przypomina mowę (np. talk-show, audiobook, poezja), tym wartość bliższa 1.0. Wartości powyżej 0.66 oznaczają, że utwór prawdopodobnie składa się głównie z mowy. Wartości między 0.33 a 0.66 wskazują na mieszankę muzyki i mowy (np. rap). Wartości poniżej 0.33 najczęściej oznaczają utwory muzyczne bez mowy
- **acousticness**: Miara (od 0.0 do 1.0) określająca prawdopodobieństwo, że utwór jest akustyczny. Wartość 1.0 oznacza wysoką pewność, że utwór jest akustyczny
- **instrumentalness**: Określa, czy utwór nie zawiera wokalu. Dźwięki typu „ooh” i „aah” traktowane są jako instrumentalne. Rap i mowa są uznawane za wokalne. Im wartość bliższa 1.0, tym większe prawdopodobieństwo, że utwór nie zawiera wokalu
- **liveness**: Wskaźnik obecności publiczności w nagraniu. Wyższe wartości oznaczają większe prawdopodobieństwo, że utwór został wykonany na żywo. Wartość powyżej 0.8 silnie sugeruje wykonanie na żywo
- **valence**: Miara od 0.0 do 1.0 opisująca pozytywny wydźwięk emocjonalny utworu. Utwory o wysokiej wartości brzmią bardziej pozytywnie (np. radośnie, optymistycznie), natomiast o niskiej – bardziej negatywnie (np. smutno, przygnębiająco)
- **tempo**: Szacowane tempo utworu wyrażone w uderzeniach na minutę (BPM). W terminologii muzycznej tempo oznacza szybkość utworu i wynika bezpośrednio ze średniego czasu trwania jednego uderzenia
- **time_signature**: Szacowane metrum utworu. Metrum określa liczbę uderzeń w takcie. Wartości mieszczą się w zakresie od 3 do 7, co odpowiada metrom od 3/4 do 7/4
- **track_genre**: Gatunek muzyczny, do którego należy utwór

Interesują nas zarówno analizy dotyczące poszczególnych artystów i gatunków, jak i porównanie między nimi.

Źródło danych

Maharshi Pandya. (2022). Spotify Tracks Dataset [Data set]. Kaggle. https://doi.org/10.34740/KAGGLE/DSV/4372070

Dane pierwotnie pozyskane z Spotify Web API

https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset (Dostęp/pobrane: 17 kwietnia 2026)

Licencja: https://opendatacommons.org/licenses/odbl/1-0/

1.4 Ocena

Ocenę co najmniej dostateczną (> 50%) uzyskają prace, które spełniają następujące kryteria:

1. zawierają kod potrzebny do pobrania i/lub czyszczenia danych,
2. stworzą kod, dzięki któremu zostaną wygenerowane co najmniej **dwa dla zespołów dwuosobowych/ trzy dla trzyosobowych** ciekawe wyniki (odpowiedzi na pytania „badawcze” w postaci wykresów/tabel/itp.),
3. przedstawią uzyskane wyniki w formie prezentacji.

Każda dodatkowa analiza czy nietrywialna zastosowana technika będzie wpływać pozytywnie na ocenę (np. wykresy interaktywne, animacje, aplikacje w `Shiny`, zastosowanie ciekawych metod analizy, wykorzystanie dodatkowych danych.

W szczególności, ocenę maksymalną (bardzo dobrą) uzyskają tylko prace naprawdę wyróżniające się pod względem jakościowymi i merytorycznym.

1.5 Uwaga

Każdy użytkownik Spotify może pobrać dane dotyczące swojej historii. Może to być ciekawy dodatek do projektu.